



---

# Teoria de Decisão de Bayes


---



# Modelo Probabilístico das Observações

---

- Probabilidades a priori de cada classe:  $p(\varpi_i)$  com  $i = 1, \dots, c$
- Traduz o conhecimento existente sobre a classe  $\varpi$  quando não se possui nenhuma informação adicional.
- Exemplo de classificação de dois dígitos manuscritos:




Regra de decisão:

$$\hat{\varpi} = \varpi_0 \quad \text{se } p(\varpi_0) > p(\varpi_1)$$



# Modelo Probabilístico das Observações

- Probabilidades a priori de cada classe:  $p(\varpi_i)$  com  $i = 1, \dots, c$
- Probabilidades condicionadas  $p(\mathbf{x}|\varpi_i)$  com  $i = 1, \dots, c$
- Exemplo de classificação de dois dígitos manuscritos:




Histograma (aproximação das probabilidades condicionadas)



# Modelo Probabilístico das Observações

- Probabilidades a priori de cada classe:  $p(\varpi_i)$  com  $i = 1, \dots, c$
- Probabilidades condicionadas  $p(\mathbf{x}|\varpi_i)$  com  $i = 1, \dots, c$
- Exemplo de classificação de dois dígitos manuscritos:



Funções de Densidade de Probabilidade Condicionadas  $p(\mathbf{x}|\varpi_i)$



# Modelo Probabilístico das Observações

---

- Probabilidades a priori de cada classe:  $p(\varpi_i)$  com  $i = 1, \dots, c$
- Probabilidades condicionadas  $p(\mathbf{x}|\varpi_i)$  com  $i = 1, \dots, c$
- Exemplo de classificação de dois dígitos manuscritos:

Regra de decisão:

$$\hat{\varpi} = \varpi_0 \quad \text{se} \quad p(\mathbf{x}|\varpi_0) > p(\mathbf{x}|\varpi_1)$$

(Classificador de Máxima Verosimilhança)

---



# Modelo Probabilístico das Observações

---

- Probabilidades a priori de cada classe:  $p(\varpi_i)$  com  $i = 1, \dots, c$
- Probabilidades condicionadas  $p(\mathbf{x}|\varpi_i)$  com  $i = 1, \dots, c$
- Como combinar a informação contida nas densidades a priori e nas densidades condicionadas de modo a minimizar a probabilidade de erro?

**Solução: Classificador MAP**

---



# Classificador de Máximo a Posteriori

- Pressuposto: **Conhecimento completo de todas as densidades**
- Critério adoptado: **Minimizar a probabilidade de erro**
- **Regra de decisão**: calcular a probabilidade de ocorrência de cada classe *dada a observação*  $\mathbf{x}$ , e escolher a classe mais provável:

$$\hat{\varpi} = \varpi_i \text{ se } p(\varpi_i|\mathbf{x}) > p(\varpi_k|\mathbf{x}), \forall k \neq i$$

- Lei de Bayes:

$$p(\varpi_i|\mathbf{x}) = \frac{p(\mathbf{x}|\varpi_i)p(\varpi_i)}{p(\mathbf{x})}$$
$$p(\mathbf{x}) = \sum_{i=1}^c p(\mathbf{x}|\varpi_i)p(\varpi_i)$$

onde  $p(\mathbf{x})$  é a probabilidade das observações  
(factor de escala)



# Classificador de Máximo a Posteriori

- Pressuposto: **Conhecimento completo de todas as densidades**
- Critério adoptado: **Minimizar a probabilidade de erro**
- **Regra de decisão:** calcular a probabilidade de ocorrência de cada classe *dada a observação*  $\mathbf{x}$ , e escolher a classe mais provável:

$$\hat{\varpi} = \varpi_i \text{ se } p(\varpi_i|\mathbf{x}) > p(\varpi_k|\mathbf{x}), \forall k \neq i$$

- Lei de Bayes: 
$$p(\varpi_i|\mathbf{x}) = \frac{p(\mathbf{x}|\varpi_i)p(\varpi_i)}{p(\mathbf{x})}$$

- Funções discriminantes:

$$g_i(\mathbf{x}) = p(\varpi_i|\mathbf{x})$$

ou

$$g_i(\mathbf{x}) = p(\mathbf{x}|\varpi_i)p(\varpi_i)$$

- $\hat{\varpi} = \varpi_i \text{ se } g_i(\mathbf{x}) > g_k(\mathbf{x}), \forall k \neq i$






# Classificador de Máximo a Posteriori

- Exemplo de classificação de dois dígitos manuscritos


$$p(\varpi_0) = \frac{2}{3}$$



$$p(\varpi_1) = \frac{1}{3}$$



$$g_i(x) = p(\varpi_i|x)$$



$$g_i(x) = p(x|\varpi_i)p(\varpi_i)$$



# Classificador de Máximo a Posteriori

## Probabilidade de Erro

- $p_{ik} = p(\hat{\omega} = \varpi_k | \mathbf{x} \in \varpi_i) = \int_{S_k} p(\mathbf{x} | \varpi_i) d\mathbf{x}$

- Matriz de confusão:

$$\mathbf{P} = \begin{matrix} & \begin{matrix} \hat{\omega}_1 & \hat{\omega}_2 & \cdots & \hat{\omega}_c \end{matrix} \\ \begin{matrix} \varpi_1 \\ \varpi_2 \\ \vdots \\ \varpi_c \end{matrix} & \begin{bmatrix} p_{11} & p_{12} & \cdots & p_{1c} \\ p_{21} & p_{22} & \cdots & p_{2c} \\ \vdots & \vdots & \ddots & \vdots \\ p_{c1} & p_{c2} & \cdots & p_{cc} \end{bmatrix} \end{matrix}$$

- Probabilidade total do erro:

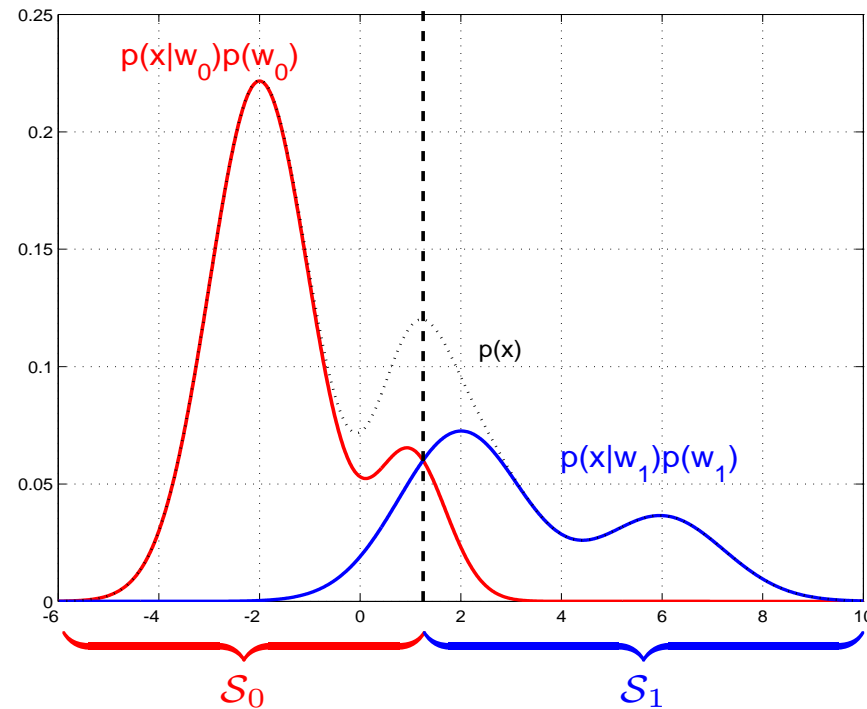
$$\mathcal{P}_{\text{erro}} = \sum_{i=1}^c \left( \underbrace{1 - \int_{S_i} p(\mathbf{x} | \varpi_i) d\mathbf{x}}_{\mathcal{P}_{\text{erro}}(\varpi_i)} \right) p(\varpi_i) = 1 - \sum_{i=1}^c p_{ii} p(\varpi_i)$$



# Classificador de Máximo a Posteriori

## Probabilidade de Erro

- Exemplo de duas classes ( $\varpi_0$  e  $\varpi_1$ )



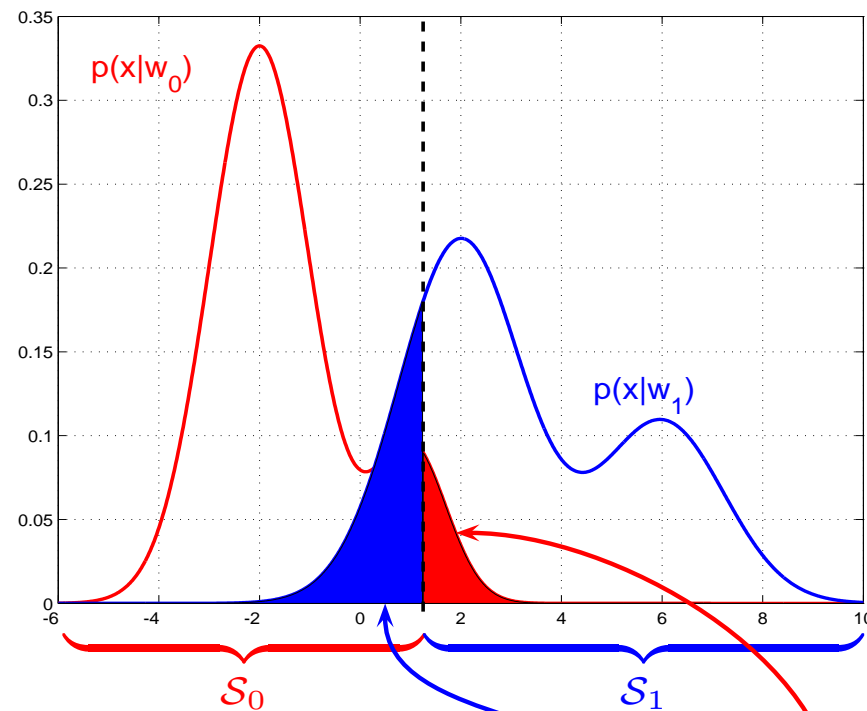
Ponto de fronteira:  $p(x|\varpi_0)p(\varpi_0) = p(x|\varpi_1)p(\varpi_1)$



# Classificador de Máximo a Posteriori

## Probabilidade de Erro

- Exemplo de duas classes ( $\varpi_0$  e  $\varpi_1$ )




Probabilidade de erro de cada classe:  $p_{10}$  e  $p_{01}$



# Classificador de Máximo a Posteriori

## Probabilidade de Erro

- Exemplo de duas classes ( $\varpi_0$  e  $\varpi_1$ )




Probabilidade total de erro  $p_{01}p(\varpi_0) + p_{10}p(\varpi_1)$  do classificador de MAP



# Classificador de Máximo a Posteriori

## Probabilidade de Erro

- Exemplo de duas classes ( $\varpi_0$  e  $\varpi_1$ )




Probabilidades total de erro aumenta para outros pontos de fronteira



# Classificador de Máximo a Posteriori

## Probabilidade de Erro

- Exemplo de duas classes ( $\varpi_0$  e  $\varpi_1$ )




Probabilidades total de erro aumenta para outros pontos de fronteira



# Classificador de Máximo a Posteriori

## Probabilidade de Erro

- Exemplo de três classes  $\varpi_1$ ,  $\varpi_2$ , e  $\varpi_3$



Probabilidades total de erro do classificador de MAP





# Classificador de Máximo a Posteriori

## Densidades gaussianas 1D: regiões e fronteiras de decisão

- Para dados 1D em que as densidades das classes são gaussianas com variâncias idênticas, as fronteiras de decisão resultam num único ponto.

Exemplo:

$$p(\varpi_1) = \frac{1}{3}, \quad p(\varpi_2) = \frac{2}{3}$$

$$p(x|\varpi_1) = \mathcal{N}(-2, 2) = \frac{1}{\sqrt{4\pi}} \exp\left(-\frac{1}{4}(x+2)^2\right)$$

$$p(x|\varpi_2) = \mathcal{N}(+2, 2) = \frac{1}{\sqrt{4\pi}} \exp\left(-\frac{1}{4}(x-2)^2\right)$$

ponto de fronteira:


$$p(\varpi_1|x) = p(\varpi_2|x)$$

$$\Leftrightarrow p(\varpi_1)p(x|\varpi_1) = p(\varpi_2)p(x|\varpi_2)$$

$$\Leftrightarrow \frac{1/3}{\sqrt{4\pi}} \exp\left(-\frac{1}{4}(x+2)^2\right) = \frac{2/3}{\sqrt{4\pi}} \exp\left(-\frac{1}{4}(x-2)^2\right)$$

$$\Leftrightarrow -\frac{1}{4}(x+2)^2 = -\frac{1}{4}(x-2)^2 + \ln 2$$

$$\Leftrightarrow x^2 + 4x + 4 = x^2 - 4x + 4 - 4 \ln 2$$



$$x = -0.35$$

$$\mathcal{S}_1 = [-\infty, -0.35]$$

$$\mathcal{S}_2 = [-0.35, +\infty]$$



# Classificador de Máximo a Posteriori

## Densidades gaussianas 1D: regiões e fronteiras de decisão

- Para dados 1D em que as densidades das classes são gaussianas com variâncias distintas, as fronteiras de decisão resultam em dois pontos.

Exemplo:

$$p(\varpi_1) = \frac{1}{3}, \quad p(\varpi_2) = \frac{2}{3}$$

$$p(x|\varpi_1) = \mathcal{N}(-1, 1) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}(x+1)^2\right)$$

$$p(x|\varpi_2) = \mathcal{N}(+1, 4) = \frac{1}{\sqrt{8\pi}} \exp\left(-\frac{1}{8}(x-1)^2\right)$$

pontos de fronteira:


$$p(\varpi_1|x) = p(\varpi_2|x)$$

$$\Leftrightarrow p(\varpi_1)p(x|\varpi_1) = p(\varpi_2)p(x|\varpi_2)$$

$$\Leftrightarrow \frac{1/3}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}(x+1)^2\right) = \frac{2/3}{\sqrt{8\pi}} \exp\left(-\frac{1}{8}(x-1)^2\right)$$

$$\Leftrightarrow -\frac{1}{2}(x+1)^2 = -\frac{1}{8}(x-1)^2$$

$$\Leftrightarrow 4x^2 + 8x + 4 = x^2 - 2x + 1$$



$$x = \{-3, -\frac{1}{3}\}$$

$$\mathcal{S}_1 = [-3, -\frac{1}{3}]$$

$$\mathcal{S}_2 = [-\infty, -3] \cup [-\frac{1}{3}, +\infty]$$



# Classificador de Máximo a Posteriori

## Densidades gaussianas 1D:

● Probabilidade de erro.

Exemplo:

$$p(\varpi_1) = \frac{1}{3}, \quad p(\varpi_2) = \frac{2}{3}$$

$$p(x|\varpi_1) = \mathcal{N}(-1, 1) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}(x+1)^2\right)$$

$$p(x|\varpi_2) = \mathcal{N}(+1, 4) = \frac{1}{\sqrt{8\pi}} \exp\left(-\frac{1}{8}(x-1)^2\right)$$

pontos de fronteira:


$$x = \left\{-3, -\frac{1}{3}\right\}$$

$$\mathcal{S}_1 = \left[-3, -\frac{1}{3}\right]$$

$$\mathcal{S}_2 = \left[-\infty, -3\right] \cup \left[-\frac{1}{3}, +\infty\right]$$

probabilidade total de erro:

$$\mathcal{P}_{\text{erro}} = p(\varpi_1) \int_{\mathcal{S}_2} p(x|\varpi_1) dx + p(\varpi_2) \int_{\mathcal{S}_1} p(x|\varpi_2) dx = p(\varpi_1)p_{12} + p(\varpi_2)p_{21}$$







# Classificador de Máximo a Posteriori

## Densidades gaussianas 1D:

- Cálculo de áreas de gaussianas

- Função de erro:  $\text{erf}(\alpha) = \int_{-\alpha}^{+\alpha} \frac{1}{\sqrt{\pi}} \exp(-x^2) dx$   
área de  $[-\alpha, +\alpha]$ , duma gaussiana  $\mathcal{N}(0, \frac{1}{2})$





# Classificador de Máximo a Posteriori

## Densidades gaussianas 1D:

- Cálculo de áreas de gaussianas:

$$\int_{\mu-\alpha}^{\mu+\alpha} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right) dx$$

Mudança de variável:

$$y = \frac{x-\mu}{\sqrt{2\sigma^2}}$$

$$\frac{dy}{dx} = \frac{1}{\sqrt{2}\sigma}$$

$$\Longleftrightarrow dx = \sqrt{2}\sigma dy$$

intervalos

$$x_{\text{limites}} = [\mu - \alpha, \mu + \alpha]$$

$$\Longleftrightarrow y_{\text{limites}} = \left[\frac{-\alpha}{\sqrt{2}\sigma}, \frac{+\alpha}{\sqrt{2}\sigma}\right]$$

integral

$$\int_{-\alpha+\mu}^{\mu+\alpha} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right) dx$$

$$\Longleftrightarrow \int_{\frac{-\alpha}{\sqrt{2}\sigma}}^{\frac{+\alpha}{\sqrt{2}\sigma}} \frac{1}{\sqrt{\pi}} \exp(-y^2) dy = \text{erf}\left(\frac{\alpha}{\sqrt{2}\sigma}\right)$$




# Classificador de Máximo a Posteriori

## Densidades gaussianas 1D:

- Cálculo de áreas de gaussianas:

$$\text{erf}\left(\frac{\alpha}{\sqrt{2}\sigma}\right) = \int_{\mu-\alpha}^{\mu+\alpha} \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right) dx$$





# Classificador de Máximo a Posteriori

## Densidades gaussianas 1D:

Exemplo:

$$p(\varpi_1) = \frac{1}{3}, \quad p(\varpi_2) = \frac{2}{3}$$

$$p(x|\varpi_1) = \mathcal{N}(-1, 1) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}(x+1)^2\right)$$

$$p(x|\varpi_2) = \mathcal{N}(+1, 4) = \frac{1}{\sqrt{8\pi}} \exp\left(-\frac{1}{8}(x-1)^2\right)$$

pontos de fronteira:

$$x = \left\{-3, -\frac{1}{3}\right\}$$

$$\mathcal{S}_1 = \left[-3, -\frac{1}{3}\right]$$


$$\mathcal{S}_2 = \left[-\infty, -3\right] \cup \left[-\frac{1}{3}, +\infty\right]$$

probabilidade total de erro:

$$\mathcal{P}_{\text{erro}} = p(\varpi_1) \int_{\mathcal{S}_2} p(x|\varpi_1) dx + p(\varpi_2) \int_{\mathcal{S}_1} p(x|\varpi_2) dx = p(\varpi_1)p_{12} + p(\varpi_2)p_{21}$$

$$p_{12} = \frac{1}{2} \left( 1 - \operatorname{erf} \left( \frac{1 - 1/3}{\sqrt{2}} \right) \right) + \frac{1}{2} \left( 1 - \operatorname{erf} \left( \frac{2}{\sqrt{2}} \right) \right)$$

$$p_{21} = \frac{1}{2} \left( 1 - \operatorname{erf} \left( \frac{1 + 1/3}{2\sqrt{2}} \right) \right) - \frac{1}{2} \left( 1 - \operatorname{erf} \left( \frac{4}{2\sqrt{2}} \right) \right)$$







# Classificador de Máximo a Posteriori

## Densidades gaussianas 2D: regiões e fronteiras de decisão

- Quando as matrizes de covariância são idênticas, as fronteiras de decisão são lineares



$$\Sigma = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$



$$\Sigma = \begin{bmatrix} 0.68 & -0.32 \\ -0.32 & 0.68 \end{bmatrix}$$







# Classificador de Máximo a Posteriori

## Densidades gaussianas 2D: regiões e fronteiras de decisão

- Quando as matrizes de covariância são diferentes, as fronteiras de decisão são curvas



$$\Sigma = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \quad \Sigma = \begin{bmatrix} 0.68 & -0.32 \\ -0.32 & 0.68 \end{bmatrix}$$



$$\Sigma = \begin{bmatrix} 1 & 0 \\ 0 & 0.25 \end{bmatrix} \quad \Sigma = \begin{bmatrix} 0.34 & -0.16 \\ -0.16 & 0.34 \end{bmatrix}$$



# Classificador de Máximo a Posteriori

---

## Exercícios:

Considere que  $x$  é uma observação gerada por uma de duas classes  $\Omega = \{\varpi_1, \varpi_2\}$ , de acordo com:

$$p(x|\varpi_1) = e^{-x}u(x)$$
$$p(x|\varpi_2) = \frac{1}{3} (u(x) - u(x-3))$$

onde  $u(x)$  é a função escalão. As probabilidades *a priori* de cada classe são  $p(\varpi_1) = \frac{e}{e+3}$  e  $p(\varpi_2) = \frac{3}{e+3}$ . Para o classificador de MAP, determine:

1. As regiões de decisão.
  2. A matriz de confusão.
  3. A probabilidade total do erro.
-



# Classificador de Máximo a Posteriori

---

## Exercícios:

Seja  $x$  uma variável aleatória gerada por uma de duas classes  $\varpi_1$  e  $\varpi_2$  com as seguintes distribuições:

$$\begin{aligned} p(x|\varpi_1) &= \mathcal{N}(-1, 2) & p(\varpi_1) &= 0.7 \\ p(x|\varpi_2) &= \mathcal{N}(1, \frac{1}{2}) & p(\varpi_2) &= 0.3 \end{aligned}$$

Para o classificador de MAP, determine:

1. As regiões de decisão.
  2. A matriz de confusão.
  3. A probabilidade total do erro.
-



# Classificador de Bayes

---

- Classificador de MAP minimiza a probabilidade de erro de classificação.
  - Critério nem sempre recomendável visto que diferentes tipos de erros podem ter consequências variadas.
    - Sistema de detecção de incêndios florestais.
    - Sistema de detecção de aviões baseados em radar.
    - Sistema de despistagem de tumores em imagens médicas.
  - Preferível haver menos *falhas de detecção* em detrimento do aumento da probabilidade de *falsos alarmes*.
  - **Solução:** Atribuir custos a cada decisão.
-



# Classificador de Bayes

- Pressuposto: **Conhecimento completo de todas as densidades**
- Critério adoptado: **Minimizar o custo médio ou risco**
- Atribuição de custos:  $\lambda(\hat{\omega}_j | \varpi_i) = \lambda_{ij}$  é o custo de classificar  $x$  na classe  $\varpi_j$ , dado que foi a classe  $\varpi_i$  que gerou  $x$ 
  - *A matriz de custo,  $\Lambda$ , representa todas as combinações possíveis de  $\hat{\omega}$  e  $\varpi$ :*

$$\Lambda = \begin{matrix} & \hat{\omega}_1 & \hat{\omega}_2 & \cdots & \hat{\omega}_c \\ \begin{matrix} \varpi_1 \\ \varpi_2 \\ \vdots \\ \varpi_c \end{matrix} & \begin{bmatrix} \lambda_{11} & \lambda_{12} & \cdots & \lambda_{1c} \\ \lambda_{21} & \lambda_{22} & \cdots & \lambda_{2c} \\ \vdots & & \ddots & \vdots \\ \lambda_{c1} & \lambda_{c2} & \cdots & \lambda_{cc} \end{bmatrix} \end{matrix}$$



# Classificador de Bayes

- Pressuposto: **Conhecimento completo de todas as densidades**
- Critério adoptado: **Minimizar o custo médio ou risco**
- $\lambda_{ij}$ : custo de decidir que  $\hat{\omega} = \varpi_j$ , quando  $\omega = \varpi_i$
- Custo associado a  $\hat{\omega} = \varpi_i$ :

$$\lambda_i(\mathbf{x}) = \sum_{k=1}^c \lambda_{ki} p(\varpi_k | \mathbf{x}) = \sum_{k=1}^c \lambda_{ki} \frac{p(\mathbf{x} | \varpi_k) p(\varpi_k)}{p(\mathbf{x})}$$

- **Regra de decisão**: dada a observação  $\mathbf{x}$ , calcular o custo,  $\lambda_i(\mathbf{x})$ , associado a cada decisão  $\hat{\omega} = \varpi_i$ , e escolher o a classe correspondente ao **menor** custo (oposto de funções discriminantes):

$$\hat{\omega} = \varpi_i \text{ se } \lambda_i(\mathbf{x}) < \lambda_k(\mathbf{x}), \forall k \neq i$$

- Funções discriminantes:  $g_i(\mathbf{x}) = -\lambda_i(\mathbf{x})$



# Classificador de Bayes

- Pressuposto: **Conhecimento completo de todas as densidades**
- Critério adoptado: **Minimizar o custo médio ou risco**
- $\lambda_{ij}$ : custo de decidir que  $\hat{\omega} = \varpi_j$ , quando  $\omega = \varpi_i$
- Custo associado a  $\hat{\omega} = \varpi_i$ :  $\lambda_i(\mathbf{x}) = \sum_{k=1}^c \lambda_{ki} p(\varpi_k | \mathbf{x})$
- Regra de decisão:  $\hat{\omega} = \varpi_i$  se  $\lambda_i(\mathbf{x}) < \lambda_k(\mathbf{x}), \forall k \neq i$
- **Risco** associado a  $\hat{\omega} = \varpi_i$ :

$$\mathcal{R}_i = \sum_{k=1}^c \int_{\mathcal{S}_i} \lambda_{ki} p(\mathbf{x} | \varpi_k) p(\varpi_k) d\mathbf{x} = \int_{\mathcal{S}_i} \lambda_i(\mathbf{x}) p(\mathbf{x}) d\mathbf{x}$$

- **Risco Total:**  $\mathcal{R} = \sum_{i=1}^c \mathcal{R}_i = \sum_{i=1}^c \int_{\mathcal{S}_i} \lambda_i(\mathbf{x}) p(\mathbf{x}) d\mathbf{x}$



# Classificador de Bayes


Exemplo de duas classes:

● Custo da decisão  $\hat{w} = w_i$ :

$$\lambda_1(\mathbf{x}) = 3.0p(w_2|\mathbf{x})$$

$$\lambda_2(\mathbf{x}) = 1.5p(w_1|\mathbf{x})$$

$$\Lambda = \begin{bmatrix} 0 & 1.5 \\ 3.0 & 0 \end{bmatrix}$$







# Classificador de Bayes

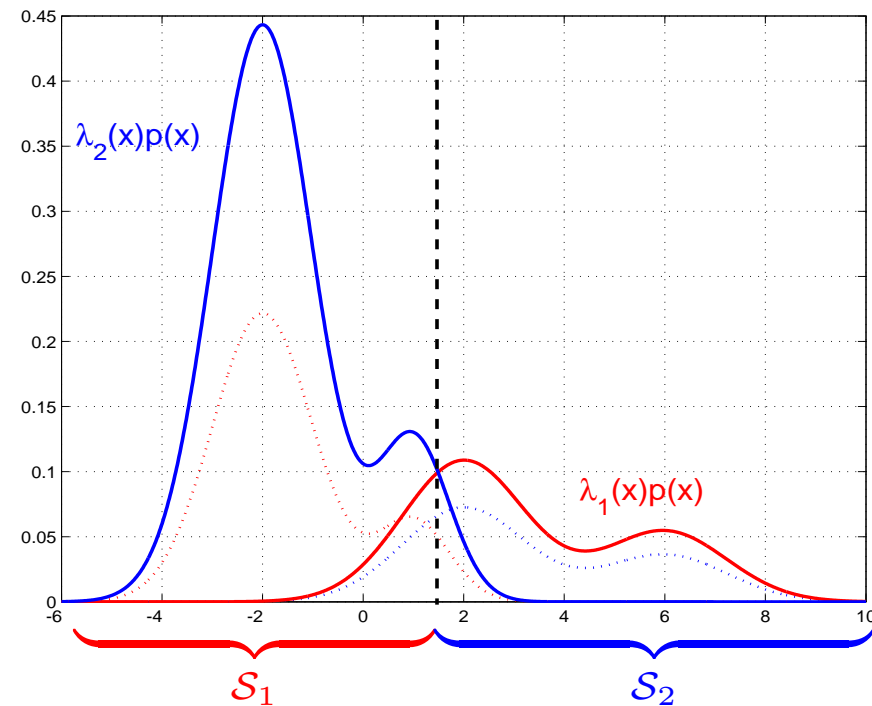
Exemplo de duas classes:

● Custo da decisão  $\hat{\omega} = \varpi_i$ :

$$\lambda_1(\mathbf{x}) = 1.5p(\varpi_2|\mathbf{x})$$

$$\lambda_2(\mathbf{x}) = 3.0p(\varpi_1|\mathbf{x})$$

$$\Lambda = \begin{bmatrix} 0 & 3.0 \\ 1.5 & 0 \end{bmatrix}$$





# Classificador de Bayes


Exemplo de duas classes:

● Custo da decisão  $\hat{w} = w_i$ :

$$\lambda_1(\mathbf{x}) = 1.5p(w_2|\mathbf{x})$$

$$\lambda_2(\mathbf{x}) = 1.5p(w_1|\mathbf{x})$$

$$\Lambda = \begin{bmatrix} 0 & 1.5 \\ 1.5 & 0 \end{bmatrix}$$





# Classificador de Bayes

## Exemplo de duas classes:

- Generalizando, o custo da decisão  $\hat{\omega} = \varpi_i$  é:

$$\lambda_1(\mathbf{x}) = \lambda_{11}p(\varpi_1|\mathbf{x}) + \lambda_{21}p(\varpi_2|\mathbf{x})$$

$$\lambda_2(\mathbf{x}) = \lambda_{12}p(\varpi_1|\mathbf{x}) + \lambda_{22}p(\varpi_2|\mathbf{x})$$

- Regra de decisão:  $\hat{\omega} = \varpi_1$  se  $\lambda_1(\mathbf{x}) < \lambda_2(\mathbf{x})$

$$(\lambda_{21} - \lambda_{22}) p(\varpi_2|\mathbf{x}) < (\lambda_{12} - \lambda_{11}) p(\varpi_1|\mathbf{x})$$

- Geralmente  $\lambda_{12} - \lambda_{11}$  e  $\lambda_{21} - \lambda_{22}$  são valores positivos. Isto é, o custo é mais elevado quando se comete um erro.

- Para  $(\lambda_{12} - \lambda_{11}) > 0$  então  $\hat{\omega} = \varpi_1$  se:

$$\frac{p(\mathbf{x}|\varpi_1)}{p(\mathbf{x}|\varpi_2)} > \frac{(\lambda_{21} - \lambda_{22}) p(\varpi_2)}{(\lambda_{12} - \lambda_{11}) p(\varpi_1)}$$



# Classificador de Bayes

## Exemplo: Filtro de SPAM

- Temos duas classes:
  - $\varpi_1$  mail normal com  $p(\varpi_1) = 0.5$
  - $\varpi_2$  mail SPAM com  $p(\varpi_2) = 0.5$
- Temos duas acções associadas ao resultado do classificador: se for um mail normal guardamos o mail, caso contrário apagamos o mail.

- Matriz de custos: 
$$\Lambda = \begin{bmatrix} 0 & 3 \\ 1 & 0 \end{bmatrix}$$

É pior apagar um mail normal do que guardar um mail SPAM.

- Recebemos um mail que tem um vector de características  $\mathbf{x}$  com  $p(\mathbf{x}|\varpi_1) = 0.3$  e com  $p(\mathbf{x}|\varpi_2) = 0.8$ . Qual das acções é tomada pelo classificador de Bayes?



# Classificador de Bayes

---

- Classificador de Bayes é o **classificador ótimo** em termos da minimização do risco
- O classificador de MAP é um caso particular do classificador de Bayes

**Necessário ter o conhecimento completo de todas as densidades**

---