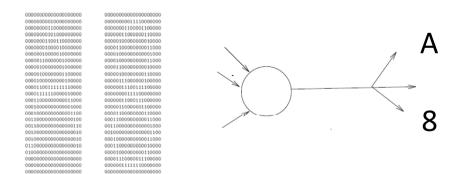
# 4º CAPÍTULO

#### Conceitos de Reconhecimento de Padrões



Prof. Arnaldo Abrantes

## Reconhecimento de padrões

- <u>Definição</u>: ao processo de atribuir uma etiqueta (classe) à instância de objecto observado designa-se por classificação
  - Porquê a necessidade da classe de rejeição?
  - Exemplo: reconhecimento de caracteres, classificação de frutos
- Definição: ao processo de fazer corresponder (ou não) uma instância de um objecto com um protótipo específico designa-se por verficação
  - Exemplo: verificação de identidade num ATM

# Modelo de sistema de classificação

- Componentes dum sistema de classificação
  - Classes

$$C_1, C_2, \cdots, C_{m-1}$$

- classe de rejeição  $C_m = C_r$
- Sensores
- Extracção de características (features)
- Classificador
  - assinatura mais próxima
  - k-vizinhos mais próximos distance or MAP probability computations input • rede neuronal feature  $f_1(x,K)$ • árvore de decisão vector output classification Х  $f_2(x,K)$ compare  $\sim C(x)$ decide  $f_{\mathbf{m}}(x,K)$

#### • Definições:

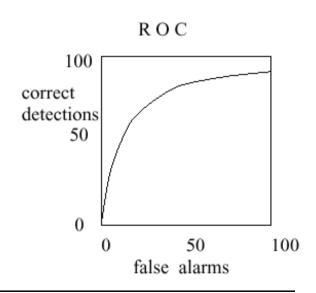
- o classificador comete um <u>erro de classificação</u> sempre que classifica um objecto na classe  $C_i$  e a verdadeira classe é  $C_j$   $(i \neq j; C_i \neq C_r)$
- <u>taxa experimental de erros</u> é igual ao número de erros de classificação, cometidos nos dados de teste independentes, a dividir pelo número de testes efectuadas
- taxa experimental de rejeições é igual ao número de rejeições feitas nos dados de teste independentes a dividir pelo número de testes efectuados
- designa-se por <u>dados de teste independentes</u> a um conjunto de amostras de classe conhecida, incluindo objectos da classe rejeição, que não foram usados no desenvolvimento do algoritmo de extracção de características nem no algoritmo de classificação (não foram usados no treino)

# Avaliação do sistema (cont.)

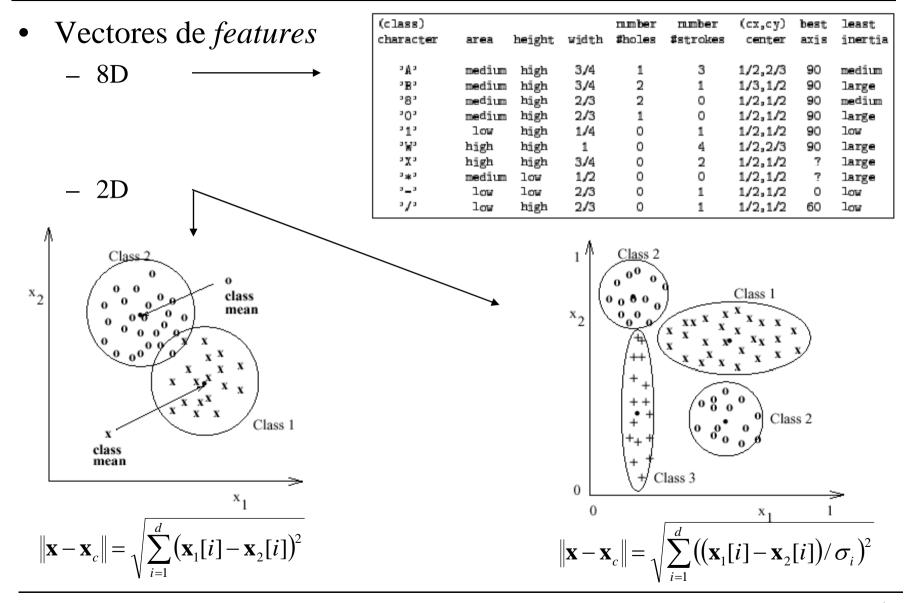
Matriz de confusão

class j output by the pattern recognition system													
		30 3	"1"	223	131	141	151	<sup>3</sup> 6 <sup>3</sup>	"7"	181	191	υR υ	
	, O ,	97	0	0	0	0	0	1	0	0	1	1	
	"1"	0	98	0	0	1	0	0	1	0	0	0	
true	121	0	0	96	1	0	1	0	1	0	0	1	
object	131	0	0	2	95	0	1	0	0	1	0	1	
class	141	0	0	0	0	98	0	0	0	0	2	0	
	151	0	0	0	1	0	97	0	0	0	0	2	
i	161	1	0	0	0	0	1	98	0	0	0	0	
	171	0	0	1	0	0	0	0	98	0	0	1	
	181	0	0	0	1	0	0	1	0	96	1	1	
	191	1	0	0	0	3	0	0	0	1	95	0	

- Problemas envolvendo apenas 2 classes
  - Exemplos
    - objecto em bom estado / objecto em mau estado
    - objecto presente na imagem / objecto ausente
    - pessoa com doença D / pessoa sem doença D
  - Conceitos
    - Falsos alarmes (falso positivo) vs falhas de detecção (falso negativo)
    - Precisão vs rechamada



## Vectores de features e classificação



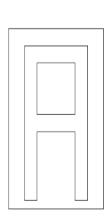
## Classificador – k-vizinhos mais próximos

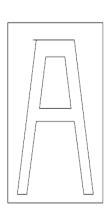
```
S is a set of n labeled class samples s_i where s_i is a feature vector and s_i is its integer
class label.
x is the unknown input feature vector to be classified.
A is an array capable of holding up to k samples in sorted order by distance d.
The value returned is a class label in the range [1, m]
      procedure K_Nearest_Neighbors(x, S)
      make A empty:
      for all samples s_i in S
         d = \text{Euclidean distance between } s_i \text{ and } \mathbf{x};
         if A has less than k elements then insert (d, s_i) into A:
         else if d is less than max A.
           then {
                   remove the max from A:
                   insert (d, s_i) in A;
      assert A has k samples from S closest to \mathbf{x}:
      if a majority of the labels s_i of from A are class c_0
         then classify x into class c_o;
         else classify \mathbf{x} into the reject class:
      return(class_of_x):
```

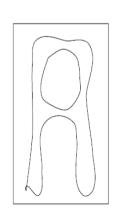
# Representação por Grafo de Estrutura

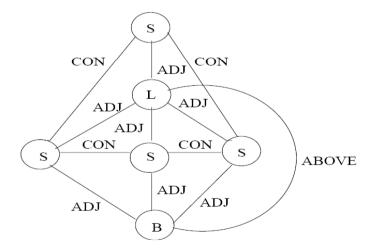
0	0	0	0	0	0	0	0	0	0
0	0	1	1	1	1	1	1	1	0
0	1	0	0	0	0	0	0	1	0
0	1	0	0	0	0	0	0	0	0
0	1	0	0	0	0	0	0	0	0
0	1	1	1	1	1	1	0	0	0
0	0	0	0	0	0	0	1	0	0
0	0	0	0	0	0	0	0	1	0
0	0	0	0	0	0	0	1	1	0
0	1	0	0	0	1	1	1	0	0
0	0	1	1	1	1	0	0	0	0
0	0	0	0	0	0	0	0	0	0

0	0	0	0	0	0	0	0	0	0
0	1	1	1	1	1	1	1	0	0
0	1	0	0	0	0	0	0	1	0
0	0	0	0	0	0	0	0	1	0
0	0	0	0	0	0	0	0	1	0
0	0	0	1	1	1	1	1	1	0
0	0	1	0	0	0	0	0	0	0
0	1	0	0	0	0	0	0	0	0
0	1	1	0	0	0	0	0	0	0
0	0	1	1	1	0	0	0	1	0
0	0	0	0	1	1	1	1	0	0
0	0	0	0	0	0	0	0	0	0



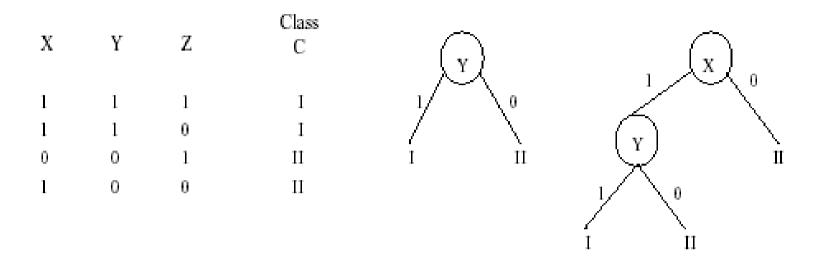






#### Classificador - árvore de decisão

input: feature vector with [ #holes, #strokes, moment of inertia ] #holes output: class of character case of #holes moment of 0: character is 1, W, X, \*, -, or / inertia case of moment about axis of least inertia large low: character is 1, -, or / case of best axis direction best axis #strokes 0: character is direction 60: character is / 90: character is 1 large: character is W or X case of #strokes 2: character is X 4: character is W CLASS 1: character is A or O case of #strokes 0: character is o 3: character is A 2: character is B or 8 case of #strokes 0: character is 8 Decision Tree Training Data 1: character is B



Training Data

Two Possible Decision Trees

- Necessidade de automatizar o processo: problemas reais podem facilmente envolver dezenas ou mesmo centenas de *features*
- •No caso das *features* tomarem valores não binários, como escolher os limiares de decisão?

# Teoria de informação e as árvores de decisão

• A entropia de um conjunto de acontecimentos  $x = \{x_1, x_2, \dots, x_n\}$  é dada por

 $H(x) = -\sum_{i=1}^{n} p_i \log_2 p_i$ 

onde  $p_i$  é a probabilidade do acontecimento  $x_i$ 

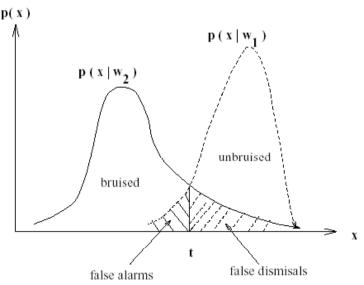
- Dado um conjunto de *features* seleccionadas, quais são aquelas que são mais informativas para o processo de classificação?
- O conteúdo de informação que a *feature* F introduz, para a determinação da classe, C, é dada pela seguinte expressão

$$I(C;F) = \sum_{i=1}^{m} \sum_{j=1}^{d} P(C = c_i, F = f_j) \log_2 \frac{P(C = c_i, F = f_j)}{P(C = c_i)P(F = f_j)}$$
Informação mútua

• Classificador MAP: um objecto é classificado na classe que é mais provável pertencer, após observação das suas *features* 

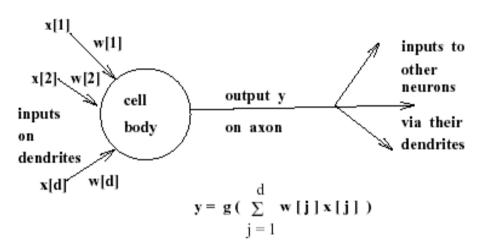
$$P(w_i \mid x) = \frac{p(x \mid w_i)P(w_i)}{p(x)}$$

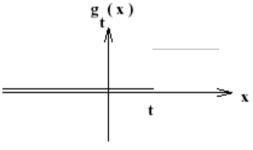
- Informação necessária:
  - Distribuição do vector de *features*, para cada classe  $\longrightarrow$   $p(x|w_i)$
  - Probabilidades a priori de cada classe



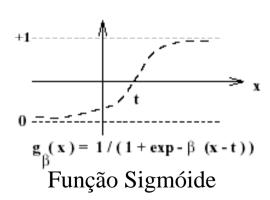
#### Redes neuronais

#### Artificial Neuron (AN)





g(x) = 1 if x > t and 0 otherwise



• Equação do hiperplano

$$\sum_{j=1}^{d} w_j x_j - t = 0$$

$$\sum_{j=0}^{d} w_j x_j = 0 \qquad w_0 = -t x_0 = 1.0$$

• Espaço de features aumentado:

$$\widetilde{x} = \begin{pmatrix} 1 & x \end{pmatrix}$$

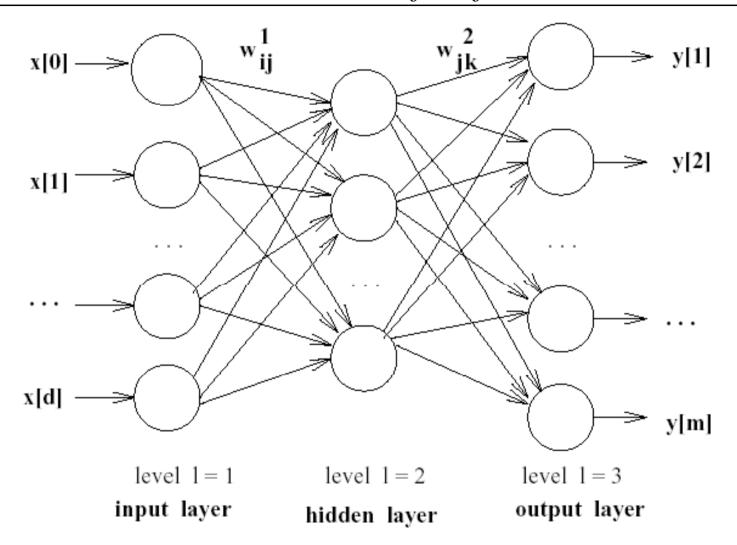
• Entrada/saída em cada neurónio

$$y = g\left(\sum_{j=0}^{d} w_j x_j\right)$$

#### Discriminantes lineares – perceptrão de incremento simples

```
Aprender ←→ Adaptar pesos
```

```
Compute weight vector w to discriminate Class 1 from 2.
S1 and S2 are sets of n samples each.
gain is a scale factor used to change w when x is misclassified.
max_passes is maximum number of passes through all training samples.
     procedure Perceptron Learning (gain, max_passes, S1, S2)
     input sample sets S1 and S2:
     choose weight vector w randomly:
      "let NE be the total number of samples misclassified"
     NE = check\_samples (S1.S2.w):
     while ( NE > 0 and passes < max.passes )
          training_pass (S1,S2,w,gain);
          NE = check\_samples (S1, S2, w):
          gain = 0.5 * gain;
           passes = passes + 1;
     report number of errors NE and weight vector w:
        procedure training pass (S1, S2, w, gain):
        for i from 1 to size of Sk.
           "scalar, or dot, product o implements AN computation"
          take next x from S1:
          if (\mathbf{w} \circ \mathbf{x} > \mathbf{0}) w = w - gain * x;
          take next \mathbf{x} from S2;
          if (\mathbf{w} \circ \mathbf{x} < \mathbf{0}) w = w + gain * x;
```



Aprendizagem → algoritmo de retropropagação