

# 8º CAPÍTULO

## Segmentação de imagem

Prof. Arnaldo Abrantes


- Objectivo: decompôr uma imagem (ou sequência de imagens) num conjunto de regiões (1d, 2d ou 3d), podendo obter-se
  - Áreas com um dado significado semântico, ou
  - Conjuntos de *pixels* de fronteira, ou
  - Estruturas de *pixels* com forma determinada (linhas, círculos, polígonos)
- Porquê realizar a operação de segmentação?
  - Isolar zonas de interesse, para posterior processamento.
  - Mudança de representação da imagem, para um nível hierárquico superior




entrada



saída



entrada




saída

## O que é uma região?

---

- Conjuntos de *pixels* conexos com ‘propriedades’ homogêneas, relativamente à(s) característica(s) (*features*) usadas na operação de segmentação
- Regiões adjacentes deverão ser significativamente diferentes, relativamente a essas mesmas *features*
- As fronteiras das regiões deverão ser suaves
- O interior duma região deverá ser simples, não devendo conter um grande número de buracos

- *Clustering*
  - Processo de decompôr (classificar) um conjunto de padrões (vetores de *features*) em diferentes subconjuntos, designados por *clusters*
- Exemplos de *features*
  - Intensidade
  - Cor
  - Textura
  - Forma
  - Movimento
- Alguns métodos
  - Algoritmos clássicos: K-médias, Isodata
  - Baseados em histogramas: Otsu, Ohlander
  - Baseados em partições de grafos: Shi



Objectivo:  $D = \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - m_k\|^2$  

Form K-means clusters from a set of n-dimensional vectors.

1. Set  $ic$  (iteration count) to 1.
2. Choose randomly a set of  $K$  means  $m_1(1), m_2(1), \dots, m_K(1)$ .
3. For each vector  $x_i$  compute  $D(x_i, m_k(ic))$  for each  $k = 1, \dots, K$  and assign  $x_i$  to the cluster  $C_j$  with the nearest mean.
4. Increment  $ic$  by 1 and update the means to get a new set  $m_1(ic), m_2(ic), \dots, m_K(ic)$ .
5. Repeat steps 3 and 4 until  $C_k(ic) = C_k(ic+1)$  for all  $k$ .



K = 6

Form isodata clusters from a set of n-dimensional vectors.

1. assign  $x_i$  to the cluster  $l$  that minimizes

$$D_{\Sigma} = [x_i - m_l]^T \Sigma_l^{-1} [x_i - m_l].$$

2. Merge clusters  $i$  and  $j$  if

$$|m_i - m_j| < \tau_v$$

where  $\tau_v$  is a variance threshold.

3. Split cluster  $k$  if the maximum eigenvalue of  $\sigma_k$  is larger than  $\tau_v$ .
4. Stop when

$$|m_i(t) - m_i(t+1)| < \epsilon$$

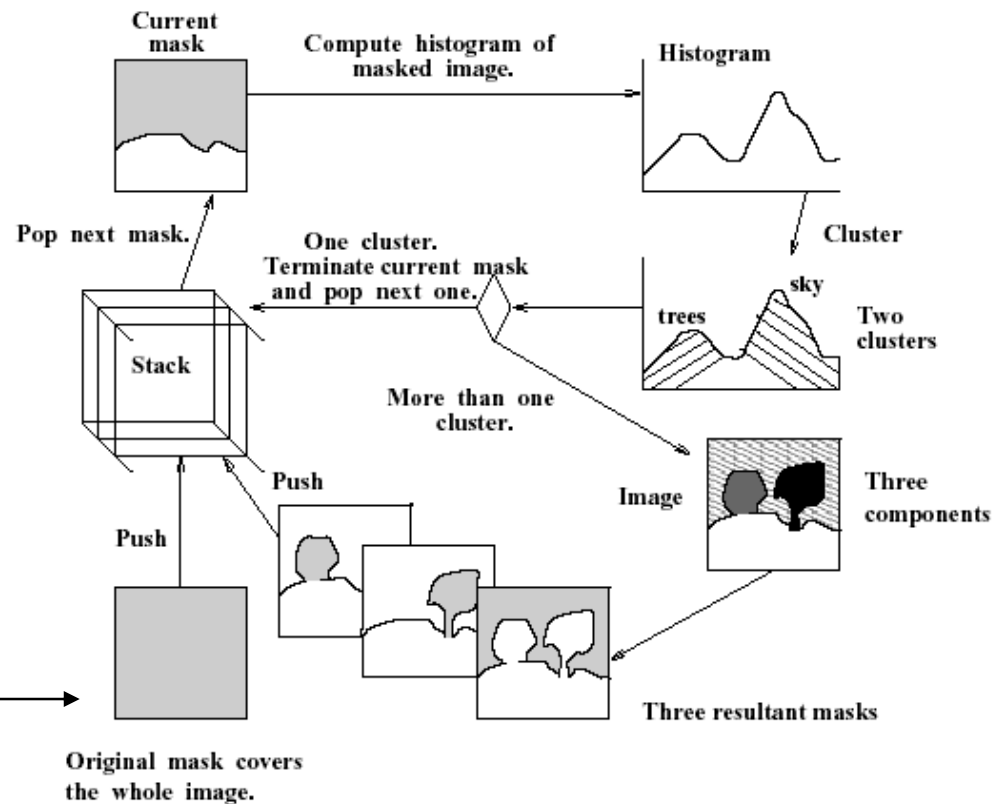
for every cluster  $i$  or when the maximum number of iterations has been reached.



K = 5


# Métodos baseados em histogramas

- Hipótese
  - Os subconjuntos de *pixels* que originam os diferentes modos do histograma, correspondem a diferentes objectos na cena (caso binário – método de Otsu)
- Vantagem
  - Métodos deste tipo necessitam de apenas uma passagem pelos dados
- Exemplo
  - Algoritmo recursivo de Ohlander



# Partição de grafos – algoritmo de Shi

- Seja o grafo  $G = (V, E)$  definido pelo conjunto de nós  $V$  e ligações  $E$ 
  - Cada nó representa um ponto no espaço de *features*
  - Cada ligação tem um peso,  $w(i, j)$ , que representa o grau de semelhança entre os nós  $i$  e  $j$
- Problema da segmentação
  - Encontrar partições do grafo, tais que as medidas de semelhança intra-partições sejam elevadas, e as inter-partições baixas
- Caso binário



(pesos inversamente proporcionais à distância entre nós)

$$\text{cut}(A, B) = \sum_{u \in A, v \in B} w(u, v)$$

$$\text{asso}(A, V) = \sum_{u \in A, t \in V} w(u, t)$$

- Caso M-ário: recursão do algoritmo binário

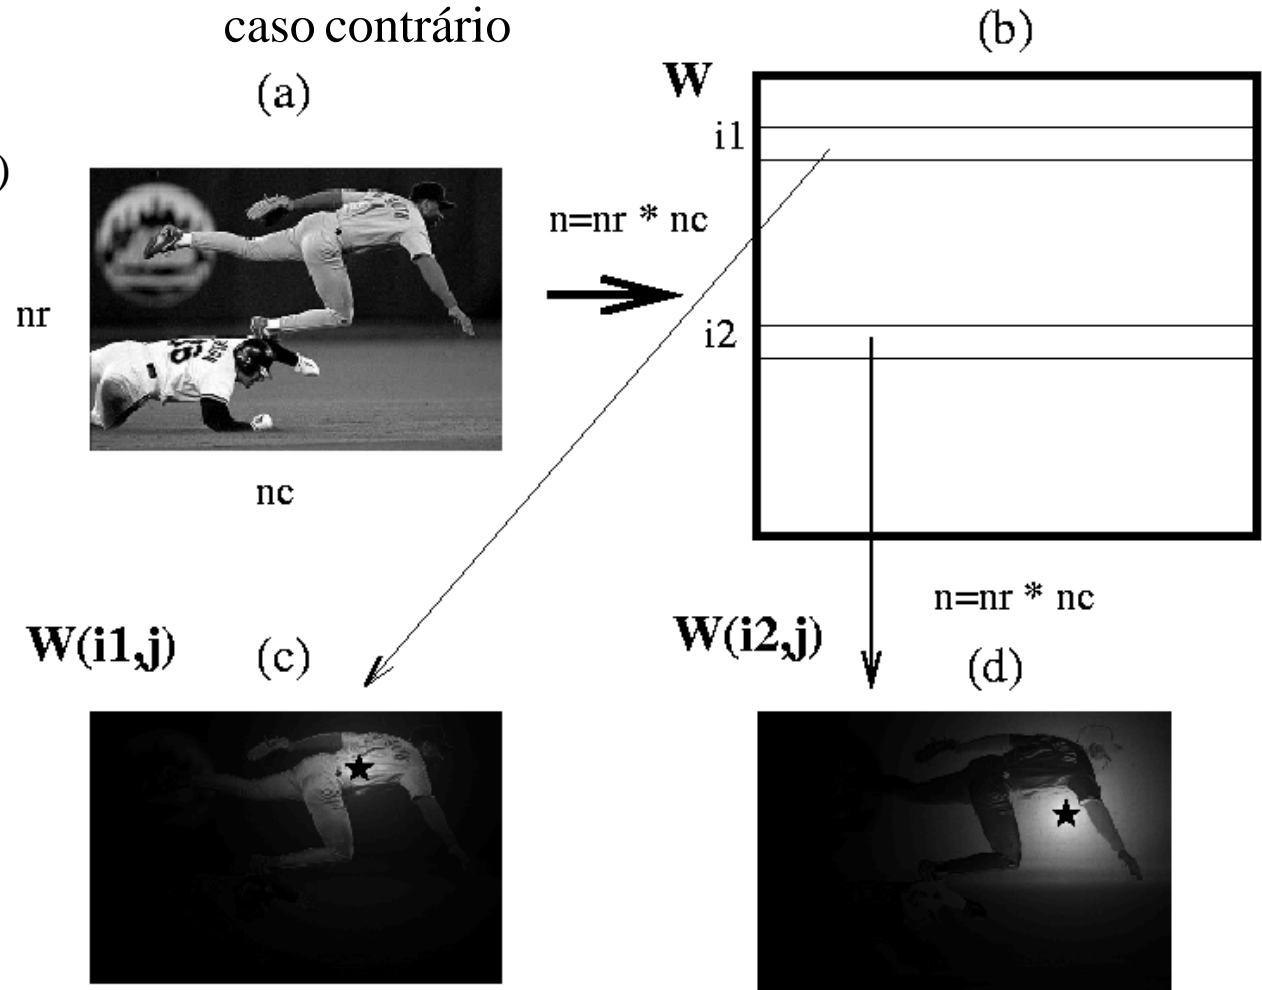
$$\text{Ncut}(A, B) = \frac{\text{cut}(A, B)}{\text{asso}(A, V)} + \frac{\text{cut}(A, B)}{\text{asso}(B, V)}$$

↑  
Minimizar Ncut

# Exemplo – Escolha da função de pesos

$$w(i, j) = e^{-\frac{\|F(i) - F(j)\|_2}{\sigma_I}} * \begin{cases} e^{-\frac{\|X(i) - X(j)\|_2}{\sigma_X}} & \text{se } \|X(i) - X(j)\|_2 < r \\ 0 & \text{caso contrário} \end{cases}$$

- $F(i), F(j)$  são vectores de *features*, (por exemplo intensidade luminosa)
- $X(i), X(j)$  são as correspondentes coordenadas dos *pixels*  $i, j$







# Resultados de segmentação – trabalho de Shi e Malik

---

original



fundo



player1



player2



símbolo



solo



- ↑
- Problema de otimização formulado como um problema de cálculo de vectores e valores próprios

- Ideias
  - Começar com uma região de um só pixel (canto superior esquerdo) e ir agrupando *pixels* a essa região enquanto as medidas de semelhança forem suficientemente elevadas
  - Iniciar uma nova região quando falha

- Critério estatístico

$$T = \left[ \frac{(N-1)N}{N+1} (y - \bar{X})^2 / S^2 \right]^{\frac{1}{2}} \quad \begin{array}{ll} T < \tau & \text{semelhante} \\ T \geq \tau & \text{não semelhante} \end{array}$$

- Actualizar, recursivamente, a média e a medida de dispersão



$$\bar{X}_{new} \leftarrow (N\bar{X}_{old} + y) / (N + 1)$$

$$\bar{X} = \frac{1}{N} \sum_{(r,c) \in R} I(r,c)$$


$$S_{new}^2 \leftarrow S_{old}^2 + (y - \bar{X}_{new})^2 + N(\bar{X}_{new} - \bar{X}_{old})^2 \quad S^2 = \sum_{(r,c) \in R} (I(r,c) - \bar{X})^2$$

# Representação de regiões


- *Overlays*




- *Chain codes*



- Imagem de *labels*



- *Quadtrees*



```

procedure border(S);
{
  for R:= 1 to NLINES
  {
    for C:= 1 to NPIXELS
    {
      LABEL:= S[R,C];
      if new_region(LABEL) then add(CURRENT,LABEL);
      NEIGHB:= neighbors(R,C,LABEL);
      T:= pixeltype(R,C,NEIGHB);
      if T == 'border'
      then for each pixel N in NEIGHB
      {
        CHAINSET:= chainlist(LABEL);
        NEWCHAIN:= true;
        for each chain X in CHAINSET while NEWCHAIN
        {
          if N==rear(X)
          then { add(X,[R,C]); NEWCHAIN:= false }
          if NEWCHAIN
          then make_new_chain(CHAINSET,[R,C],LABEL);
        }
      }
    }
    for each region REG in CURRENT
    {
      if complete(REG)
      then { connect_chains(REG); output(REG); free(REG) }
    }
  }
}

```

	1	2	3	4	5	6	7
1	0	0	0	0	0	0	0
2	0	0	0	0	2	2	0
3	0	1	1	1	2	2	0
4	0	1	1	1	2	2	0
5	0	1	1	1	2	2	0
6	0	0	0	0	2	2	0
7	0	0	0	0	0	0	0

(a) A labeled image with two regions.

Region	Length	List
1	8	(3,2)(3,3)(3,4)(4,4)(5,4)(5,3)(5,2)(4,2)
2	10	(2,5)(2,6)(3,6)(4,6)(5,6)(6,6)(6,5)(5,5) (4,5)(3,5)

(b). The output of the border procedure for the labeled image.

# Detecção e seguimento de contornos – algoritmo de Canny

- Ideias chave:
  - Supressão de não-máximos
  - Seguimento com histerese

Compute thin connected edge segments in the input image.

$I[x,y]$  : input intensity image  $\sigma$  : spread used in Gaussian smoothing;  
 $E[x,y]$  : output binary image

$IS[x,y]$  : smoothed intensity image

$Mag[x,y]$  : gradient magnitude;  $Dir[x,y]$  : gradient direction;  
 $T_{low}$  is low intensity threshold;  $T_{high}$  is high intensity threshold

procedure Canny(  $I$ ,  $\sigma$  );

```
{
     $IS$  ← image  $I$  smoothed by convolution with Gaussian  $G_\sigma(x,y)$ ;
    use Roberts operator to compute  $Mag[x,y]$  and  $Dir[x,y]$  from  $IS$ ;
    Suppress-Nonmaximal(  $Mag$ ,  $Dir$ ,  $T_{low}$ ,  $T_{high}$  );
    Edge-Detect(  $Mag$ ,  $T_{low}$ ,  $T_{high}$ ,  $E$  );
}
```

procedure Suppress-Nonmaximal(  $Mag$ ,  $Dir$  );

```
{
    define +Del[4] = (1,0), (1,1), (0,1), (-1,1);
    define -Del[4] = (-1,0), (-1,-1), (0,-1), (1,-1);
    for x := 0 to MaxX-1;
    for y := 0 to MaxY-1;
    {
        direction := (  $Dir[x,y]$  +  $\pi/8$  ) modulo  $\pi/4$ ;
        if (  $Mag[x,y]$  ≤  $Mag[x,y]$  +  $Del(direction)$  ) then  $Mag[x,y]$  := 0;
        if (  $Mag[x,y]$  ≤  $Mag[x,y]$  +  $-Del(direction)$  ) then  $Mag[x,y]$  := 0;
    }
}
```

} procedure Edge-Detect(  $Mag$ ,  $T_{low}$ ,  $T_{high}$ ,  $E$  );

```
{
    for x := 0 to MaxX-1;
    for y := 0 to MaxY-1;
    {
        if (  $Mag[x,y]$  ≥  $T_{high}$  ) then Follow-Edges(  $x,y$ ,  $Mag$ ,  $T_{low}$ ,  $T_{high}$ ,  $E$  );
    }
}
```

} procedure Follow-Edges(  $x,y$ ,  $Mag$ ,  $T_{low}$ ,  $T_{high}$ ,  $E$  );

```
{
     $E[x,y]$  := 1;
    while  $Mag[x,y]$  >  $T_{low}$  for some Neighbor  $[u,v]$  of  $[x,y]$ 
    {
         $E[u,v]$  := 1;
         $[x,y]$  :=  $[u,v]$ ;
    }
}
```

# Algoritmo de Canny - Resultados



original



$\sigma = 1$



$\sigma = 4$



original




$\sigma = 1$




Roberts



original




$\sigma = 1$



$\sigma = 2$

# Transformada de Hough – Extracção de segmentos de recta



Equação da recta:  

$$d = -r \sin \theta + c \cos \theta$$


$$\left\langle \begin{pmatrix} r - r_0 \\ c - c_0 \end{pmatrix}, \begin{pmatrix} -\sin \theta \\ \cos \theta \end{pmatrix} \right\rangle = 0$$

$$\left\langle \begin{pmatrix} r_0 \\ c_0 \end{pmatrix}, \begin{pmatrix} -\sin \theta \\ \cos \theta \end{pmatrix} \right\rangle = d$$

Exemplo:

$$\begin{aligned} d &= -50 \sin(315^\circ) + 50 \cos(315^\circ) \\ &= -50(-.707) + 50(.707) \\ &\approx 70 \end{aligned}$$

Sistema de coordenadas xy:




$$d = x \cos \theta + y \sin \theta$$

$$x \rightarrow c$$

$$y \rightarrow -r$$

Acumulador  $A(d_q, \theta_q)$



H: imagem 256x256

# Algoritmo – transformada Hough

Accumulate the straight line segments in gray-tone image S to accumulator A.

$S[R, C]$  is the input gray-tone image.

NLINES is the number of rows in the image.

NPIXELS is the number of pixels per row.

$A[DQ, THETAQ]$  is the accumulator array.

DQ is the quantized distance from a line to the origin.

THETAQ is the quantized angle of the normal to the line.

```
procedure accumulate_lines(S,A);
{
  A := 0;
  PTLIST := NIL;
  for R := 1 to NLINES
    for C := 1 to NPIXELS
      {
        DR := row_gradient(S,R,C);
        DC := col_gradient(S,R,C);
        GMAG := gradient(DR,DC);
        if GMAG > gradient_threshold
          {
            THETA := atan2(DR,DC);
            THETAQ := quantize_angle(THETA);
            D := abs(C*cos(THETAQ) - R*sin(THETAQ));
            DQ := quantize_distance(D);
            A[DQ,THETAQ] := A[DQ,THETAQ]+GMAG;
            PTLIST(DQ,THETAQ) := append(PTLIST(DQ,THETAQ),[R,C])
          }
      }
}
```



# Exemplo

## Pré-processamento

	1	2	3	4	5
1	0	0	0	100	100
2	0	0	0	100	100
3	0	0	0	100	100
4	100	100	100	100	100
5	100	100	100	100	100

gray level image

	1	2	3	4	5
1	0	0	300	300	0
2	0	0	300	300	0
3	0	0	200	200	0
4	0	0	0	100	0
5	0	0	0	0	0

column gradient

	1	2	3	4	5
1	0	0	0	0	0
2	0	0	0	0	0
3	300	300	200	100	0
4	300	300	200	100	0
5	0	0	0	0	0

row gradient

	1	2	3	4	5
1	-	-	0	0	-
2	-	-	0	0	-
3	90	90	45	26.6	-
4	90	90	90	45	-
5	-	-	-	-	-

THETA

	1	2	3	4	5
1	-	-	0	0	-
2	-	-	0	0	-
3	90	90	40	20	-
4	90	90	90	40	-
5	-	-	-	-	-

THETAQ

	1	2	3	4	5
1			3	4	
2			3	4	
3	3	3	4.2	4.8	
4	4	4	4	5.6	
5					

D

	1	2	3	4	5
1			3	3	
2			3	3	
3	3	3	3	3	
4	3	3	3	3	
5					

DQ

## Acumulador

DQ	360						
:							
6							
3	4		1		2		5
0							
	0	10	20	30	40	...	90

accumulator A

DQ	360						
:							
6							
3	♣		◇		♠		♥
0							
	0	10	20	30	40	...	90

PTLIST

- ♣ (1,3)(1,4)(2,3)(2,4)
- ◇ (3,4)
- ♠ (3,3)(4,4)
- ♥ (3,1)(3,2)(4,1)(4,2)(4,3)

# Transformada de Hough Generalizada

---

- A TH pode ser estendida para qualquer curva com expressão analítica da forma  $f(\mathbf{x}, \mathbf{a}) = 0$ ,
  - $\mathbf{x}$  é um vector 2D com as coordenadas de um ponto da curva
  - $\mathbf{a}$  é um vector de parâmetros
- Algoritmo genérico:
  - Inicializar acumulador  $A(\mathbf{a})$  a zero
  - Por cada pixel  $\mathbf{x}$  na imagem, determinar valores de  $\mathbf{a}$ , tais que  $f(\mathbf{x}, \mathbf{a}) = 0$ ; incrementar acumulador:  $A(\mathbf{a}) = A(\mathbf{a}) + 1$
  - Máximos locais de  $A$  correspondem a curvas  $f$  na imagem